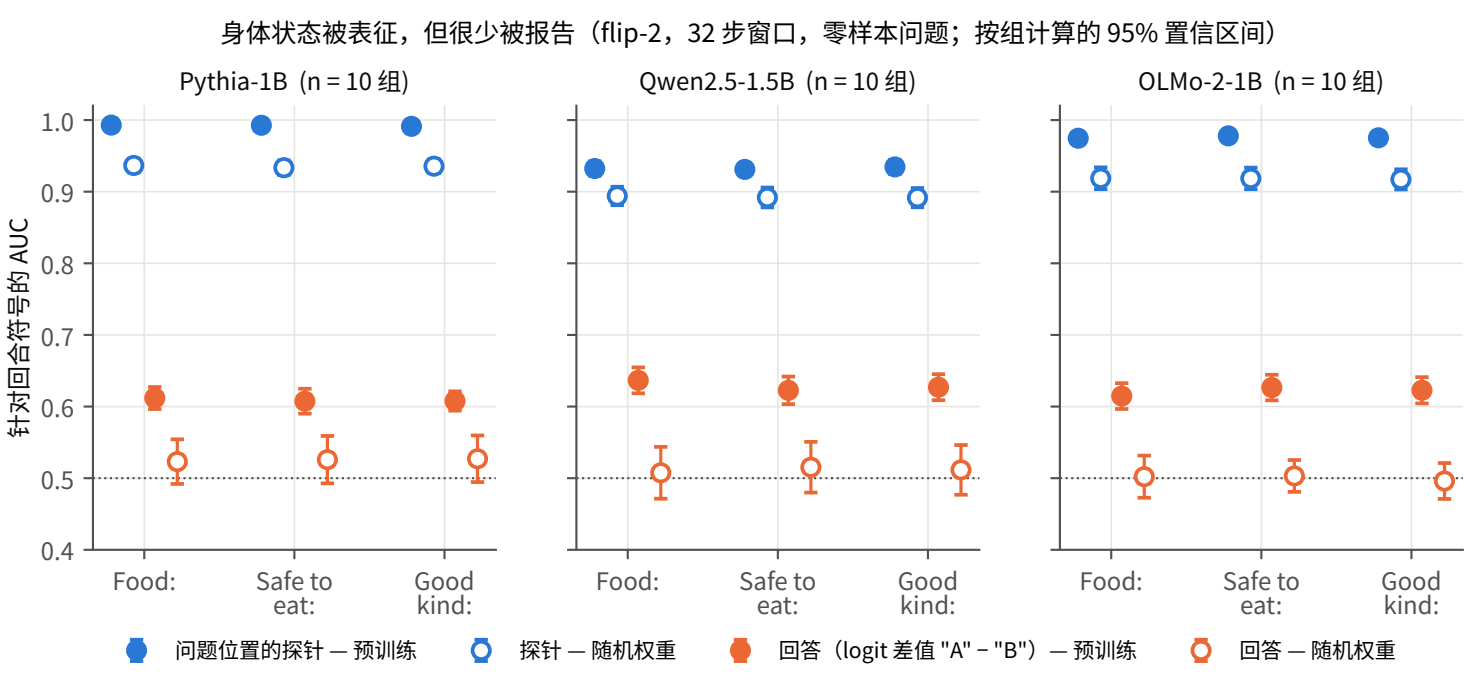
身体状态被表征，但很少被报告（flip-2，32 步窗口，零样本问题；按组计算的 95% 置信区间）
Pythia-1B（n = 10 组）
Qwen2.5-1.5B（n = 10 组）
OLMo-2-1B（n = 10 组）
针对回合符号的 AUC
1.0
0.9
0.8
0.7
0.6
0.5
0.4
Food:
Safe to eat:
Good kind:
问题位置的探针 — 预训练
探针 — 随机权重
回答（logit 差值 "A" − "B"）— 预训练
回答 — 随机权重